第六讲　批处理系统Spark

徐 辰
cxu@dase.ecnu.edu.cn
華東師範大學

Spark简介

2

- Spark由美国加州伯克利大学（UC Berkeley）的AMP实验室于2009年开发
- 最初是基于内存计算的大数据并行计算框架，用于构建大型的、低延迟的数据分析应用程序

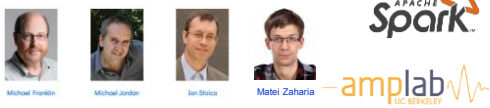

Spark简介

3

- 2013年Spark加入Apache孵化器项目后发展迅猛
- Spark在2014年打破了Hadoop保持的基准排序纪录
  - Spark/206个节点/23分钟/100TB数据
  - Hadoop/2000个节点/72分钟/100TB数据
  - Spark用十分之一的计算资源，获得了比Hadoop快3倍的速度

Spark简介

4

- Spark具有如下几个主要特点：
  - 运行速度快：使用DAG执行引擎以支持循环数据流与内存计算
  - 容易使用：支持使用Scala、Java、Python和R语言进行编程，可以通过Spark Shell进行交互式编程
  - 通用性：Spark提供了完整而强大的技术栈，包括SQL查询、流式计算、机器学习和图算法组件
  - 运行模式多样：可运行于独立的集群模式中，可运行于Hadoop中，也可运行于Amazon EC2等云环境中，并且可以访问HDFS、Cassandra、HBase、Hive等多种数据源

Spark软件栈

5

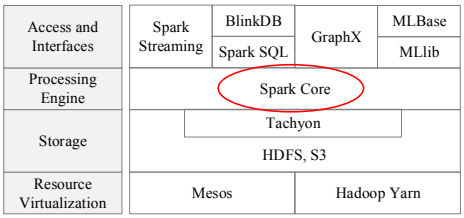

大纲

6

- 设计思想
  - MapReduce的局限性
  - 数据模型：RDD
  - 计算模型：DAG
- 体系架构
- 工作原理
- 容错机制

MapReduce

7

- MapReduce implementation principles

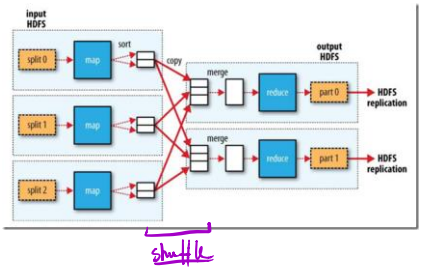

MapReduce编程范型

8

- 编程容易，不需要掌握分布式并行编程细节，很容易把程序运行在分布式系统上
- 单个基本算子太少：例如，如何join?

```
Class X {
    map() {              //map函数的实现
      ....
    }

    reduce() {           //reduce函数的实现

    }

    main(){
      Job job = …        //定义分布式作业
      job.config =       //作业参数设置
    }
}
```

单个MapReduce作业

9

- Map的结果要先写入本地磁盘，再由Reduce端来拉取

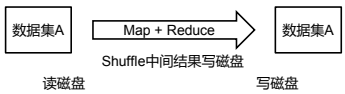

多个MapReduce作业

10

- 例子：迭代计算过程中每一迭代步结束时讲结果写入HDFS，下一步将该结果再次从HDFS读出

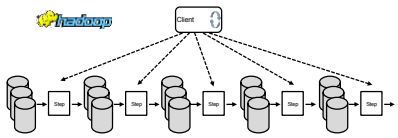

MapReduce局限性

11

- 编程框架的表达能力有限，用户编程复杂
  - 仅map和reduce函数，无法直接用join等操作
- 单个作业Shuffle阶段的数据以阻塞方式传输，磁盘IO开销大、延迟高
  - 输入、输出及shuffle中间结果都需要读写磁盘
- 多个作业之间衔接涉及IO开销，应用程序的延迟高
  - 特别是迭代计算，中间结果的反复读写，使得整个应用的延迟非常高

大纲

12

- 设计思想
  - MapReduce的局限性
  - 数据模型：RDD
  - 计算模型：DAG
- 体系架构
- 工作原理
- 容错机制

RDD概念

13

- RDD：Resilient Distributed Dataset（弹性分布式数据集）
  - 分布式内存的一个抽象概念
  - 提供了一种高度受限的共享内存模型
- RDD是可恢复的记录分区的数据集合
  - Resilient：具有可恢复的容错特性
  - Distributed：每个RDD可分成多个分区，一个RDD的不同分区可以存到集群中不同的节点上
  - Dataset：每个分区就是一个数据集片段

大纲

14

- 设计思想
  - MapReduce的局限性
  - 数据模型：RDD
  - 计算模型：DAG
- 体系架构
- 工作原理
- 容错机制

针对RDD的操作算子

15

- RDD操作支持数据运算，分为
  - 转换Transformation：描述RDD的转换逻辑
  - 动作Action：标志转换结束

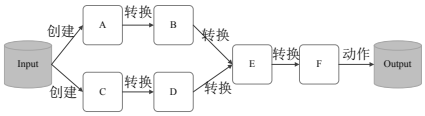

RDD运算操作

16

- 常用的API，更详细需查阅官方文档：
  http://spark.apache.org/docs/latest/rdd-programming-guide.html

常用的几个Transformation API介绍

Transformation API	说明
filter(func)	筛选出满足函数func的元素，并返回一个新的数据集
map(func)	将每个元素传递到函数func中，并将结果返回为一个新的数据集
flatMap(func)	与map()相似，但每个输入元素都可以映射到0或多个输出结果
groupByKey()	应用于(K,V)键值对的数据集时，返回一个新的(K, Iterable<V>)形式的数据集
reduceByKey(func)	应用于(K,V)键值对的数据集时，返回一个新的(K, V)形式的数据集，其中的每个值是将每个key传递到函数func中进行聚合

常用的几个Action API介绍

Action API	说明
count()	返回数据集中的元素个数
collect()	以数组的形式返回数据集中的所有元素
first()	返回数据集中的第一个元素
take(n)	以数组的形式返回数据集中的前n个元素
reduce(func)	通过函数func（输入两个参数并返回一个值）聚合数据集中的元素
foreach(func)	将数据集中的每个元素传递到函数func中运行

逻辑计算模型：Operator DAG

17

- 从算子操作的角度来描述计算的过程

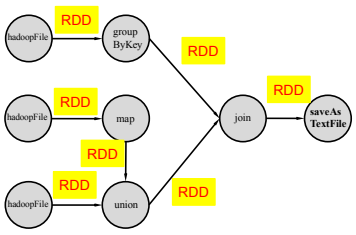

逻辑计算模型：RDD Lineage

18

- 从RDD变换的角度来描述计算过程

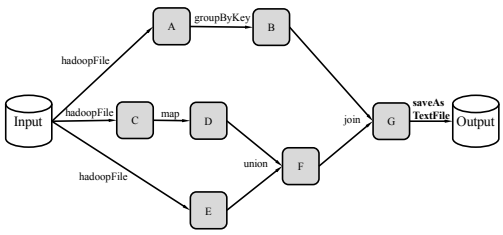

RDD Lineage

19

- RDD Lineage（即DAG拓扑结构）
  - RDD读入外部数据源进行创建
  - RDD经过一系列的转换（Transformation）操作，每一次都会产生不同的RDD，供给下一个转换操作使用
  - 最后一个RDD经过"动作"操作进行转换，并输出到外部数据源
- Spark系统保留RDD Lineage的信息
  - 为什么？

非严格情况下两个概念可以混用

RDD只读、不可变

20

- RDD是只读的记录分区的集合
  - 本质上一个只读的对象集合
  - RDD经创建后，不能进行修改
- RDD不可变（Immutable）
  - 通过在其他RDD上执行确定的转换操作（如map、join和group by）而得到新的RDD，而不是改变原有的RDD
- 遵循了函数式编程的特性

函数式编程

21

- 命令式编程(Imperative)
  - 变量值可变，对于值的操作可以直接修改原来的值，而不必新产生值
  - C/C++
- 函数式编程(Functional)
  - 变量值是不可变的，对于值的操作并不是修改原来的值，而是新产生值，原来的值保持不变
  - Scala、Java 8增加了函数式特性

X = X +1

物理计算模型：Operator DAG

22

- 分布式架构中，DAG中的操作算子实际上由若干个实例任务(Task)来实现

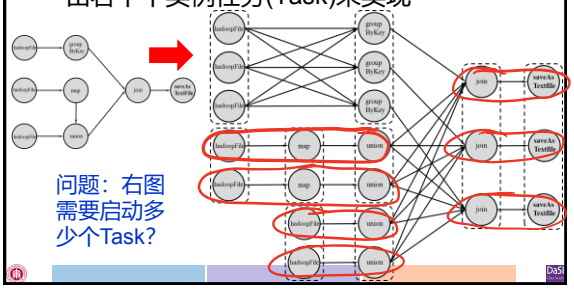

问题：右图需要启动多少个Task?

物理计算模型：RDD Lineage

23

- 每个Task通常负责处理RDD的一个分区

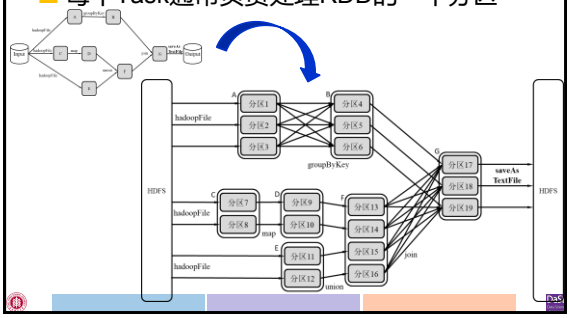

大纲

24

- 设计思想
- 体系架构
  - 架构图
  - 应用程序执行流程
- 工作原理
- 容错机制

抽象架构图

25

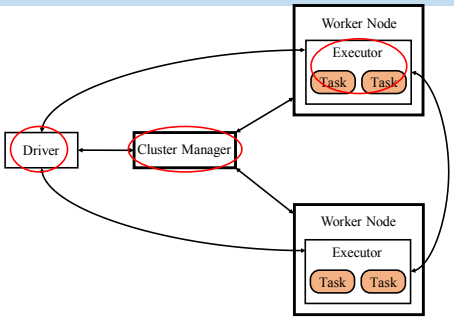

Cluster Manager

26

- 集群管理器，负责管理整个系统的资源、监控工作节点
- 根据Spark部署方式的不同，
  - 在Standalone方式（即不使用Yarn或Mesos等其它资源管理系统）中，集群管理器包含Master和Worker
  - 在Yarn方式中集群管理器包括Resource Manager和Node Manager

Executor

27

- 执行器，负责任务执行。Executor本身是运行在工作节点上的一个进程，它启动若干个线程Task或线程组TaskSet来进行执行任务
  - **MapReduce中的Task是线程还是进程?**
- 在Standalone部署方式下，Executor进程的名称为CoarseGrainedExecutorBackend

Driver

28

- 驱动器，负责启动应用程序的主函数并管理作业运行
- Driver中的SparkContext类维护了DAG、RDD lineage这些至关重要的信息

Standalone架构图

29

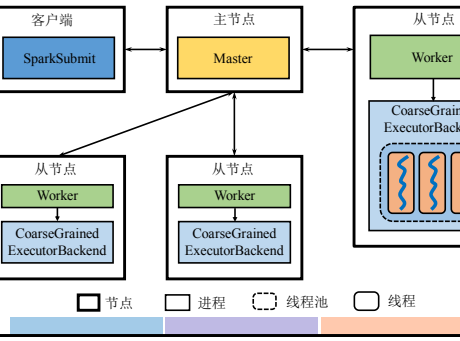

架构图比较

30

Standalone架构图	抽象架构图
SparkSubmit (Client)	/
Master	Cluster Manager
Worker	
CoarseGrained ExecutorBackend	Executor
物理节点（从节点）	Worker Node
?	Driver

Standalone中的Driver

31

- 逻辑上，Driver独立于主节点、从节点以及客户端
- 但是根据应用程序的Client或Cluster部署方式，Driver会以不同的形式存在。
  - Client部署: Driver和客户端以同一个进程存在
  - Cluster部署: 系统将由某一Worker启动一个进程作为Driver
- 客户端提交应用程序时可以选择Client或Cluster部署方式

Standalone Client

32

- Driver和客户端以同一个进程存在 可看到输出

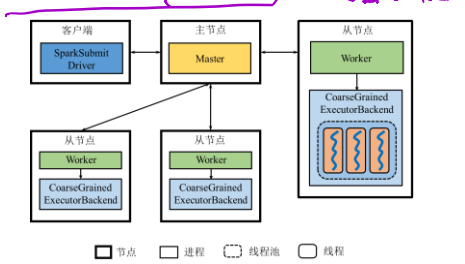

Standalone Cluster

33

- 某一Worker启动一个进程作为Driver 看不到输出

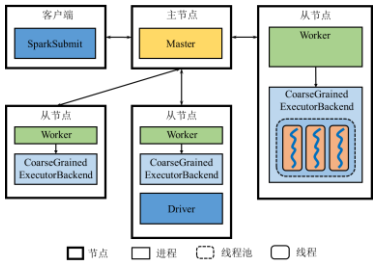

Spark vs. MapReduce

34

- 二者架构比较

	MapReduce	Spark
系统进程	JobTracker	Master
	TaskTracker	Worker
	Child	CoarseGrained ExecutorBackend
工作线程	/	TaskSet/Task
任务代码	Task	

大纲

35

- 设计思想
- 体系架构
  - 架构图
  - 应用程序执行流程
- 工作原理
- 容错机制

抽象执行流程

36

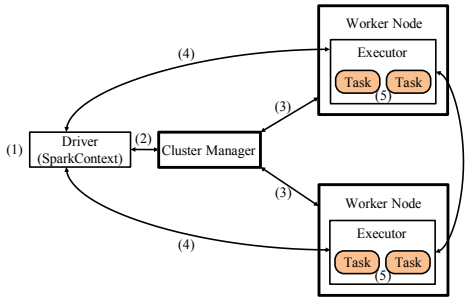

应用程序执行流程

37

1. 启动Driver，以Standalone模式为例
   - 如果使用Client部署方式，客户端直接启动Driver，并向Master注册。
   - 如果使用Cluster部署方式，客户端将应用程序提交给Master，由Master选择一个Worker启动Driver进程(DriverWrapper)。
2. 构建基本运行环境，即由Driver创建SparkContext，向Master进行资源申请，并由Driver进行任务分配和监控。

应用程序执行流程（续）

38

3. Cluster Manager通知工作节点启动Executor进程，该进程内部以多线程方式运行任务
4. Executor进程向Driver注册
5. SparkContext构建DAG并进行任务划分，从而交给Executor进程中的线程来执行任务。

大纲

39

- 设计思想
- 体系架构
- 工作原理
- 容错机制

Spark工作过程

40

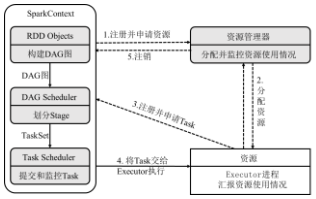

（1）构建基本运行环境，即由Driver创建SparkContext进行资源申请、任务分配和监控；根据RDD的依赖关系构建DAG图，DAG图提交给DAGScheduler解析成Stage，然后把一个个TaskSet提交给底层调度器TaskScheduler

（2）资源管理器为Executor分配资源，并启动Executor进程

（3）Executor向SparkContext注册并申请Task

（4）SparkContext中的Task Scheduler按照Stage的拓扑顺序依次将Task发放给Executor运行，并提供应用程序代码给Executor运行Task

（5）直到所有Task运行完毕后写入数据并释放所有资源

SparkContext工作过程

41

RDD在Spark架构中的运行过程：

（1）创建RDD对象；

（2）SparkContext负责计算RDD之间的依赖关系，构建DAG；

（3）DAGScheduler负责把DAG图分解成多个Stage，每个Stage中包含了多个Task，每个Task会被TaskScheduler分发给各个WorkerNode上的Executor去执行。

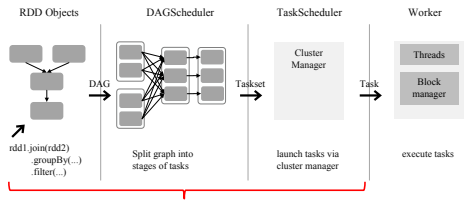

大纲

42

- 设计思想
- 体系架构
- 工作原理
  - DAG Stage划分
  - Stage内部数据交换
  - Stage之间数据交换
  - 应用、作业与任务
- 容错机制

RDD依赖关系

43

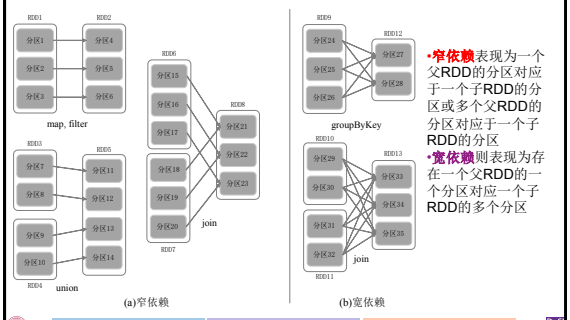

- **窄依赖**表现为一个父RDD的分区对应于一个子RDD的分区或多个父RDD的分区对应于一个子RDD的分区
- **宽依赖**则表现为存在一个父RDD的一个分区对应一个子RDD的多个分区

为什么关心依赖关系？

44

- 分析各个RDD的偏序关系生成DAG，再通过分析各个RDD中的分区之间的依赖关系来决定如何划分Stage
- 具体划分方法：
  - 在DAG中进行反向解析，遇到宽依赖就断开
  - 遇到窄依赖就把当前的RDD加入到Stage中
  - 为什么将窄依赖尽可能划分在同一个Stage？

基于RDD Lineage的Stage划分

45

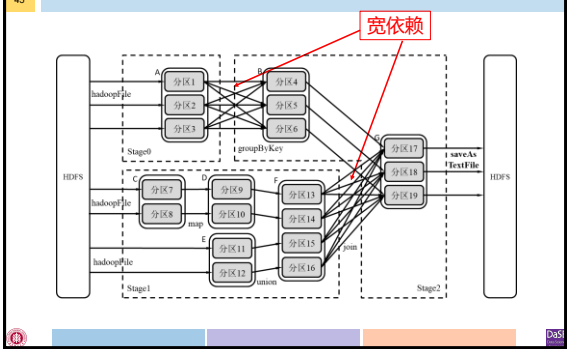

基于Operator DAG的Stage划分

46

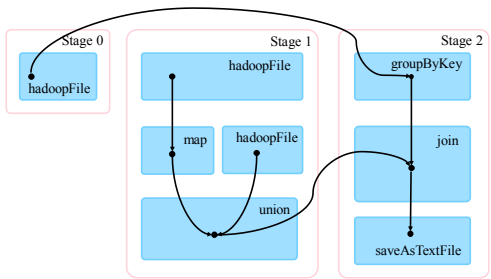

Stage类型

47

- ShuffleMapStage
  - 输入/输出
    - 输入可以是从外部获取数据，也可以是另一个ShuffleMapStage的输出
    - 以Shuffle为输出，作为另一个Stage开始
  - 特点
    - 不是最终的Stage，在它之后还有其他Stage
    - 它的输出一定需要经过Shuffle过程，并作为后续Stage的输入
    - 在一个DAG里可能有该类型的Stage，也可能没有该类型Stage

Stage类型

48

- ResultStage
  - 输入/输出
    - 其输入可以是从外部获取数据，也可以是另一个ShuffleMapStage的输出
    - 输出直接产生结果或存储
  - 特点
    - 最终的Stage
    - 在一个DAG里必定有该类型Stage
- 因此，一个DAG含有一个或多个Stage，其中至少含有一个ResultStage

ShuffleMapStage vs. ResultStage

49

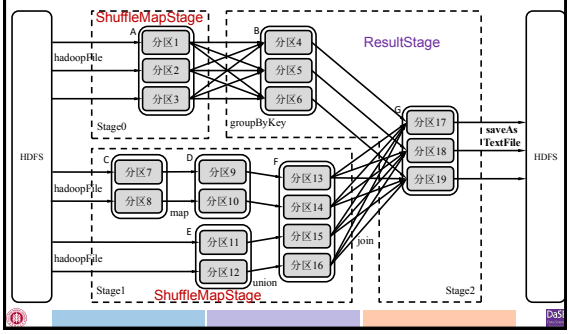

大纲

50

- 设计思想
- 体系架构
- 工作原理
  - DAG Stage划分
  - Stage内部数据交换
  - Stage之间数据交换
  - 应用、作业与任务
- 容错机制

Stage内部的特点

51

- 所有依赖关系都是窄依赖，可以实现pipeline方式进行数据传输

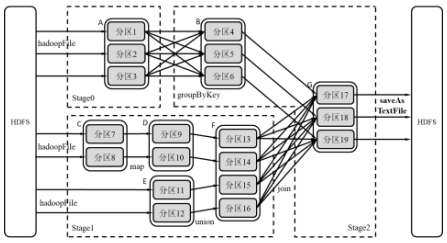

流水线（Pipeline）方式

52

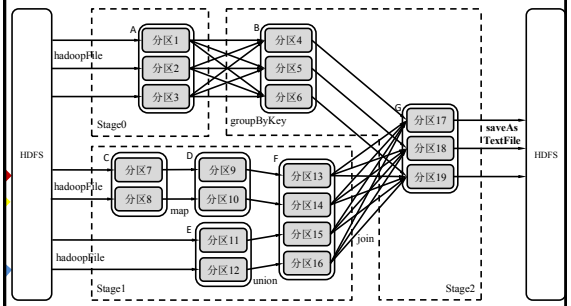

Spark Pipeline vs. MapReduce Shuffle

53

- 与MapReduce中Shuffle方式不同，流水线方式不要求物化前序算子的所有计算结果
  - 分区7通过map操作生成的分区9，并不需要物化分区9，而且可以不用等待分区8到分区10这个map操作的计算结束，继续进行union操作，得到分区13
  - 如果采用MapReduce中的Shuffle方式，那么意味着分区7、8经map计算得到分区9、10并将这两个分区进行物化之后，才可以进行union

ShuffleMapTask vs. ResultTask

54

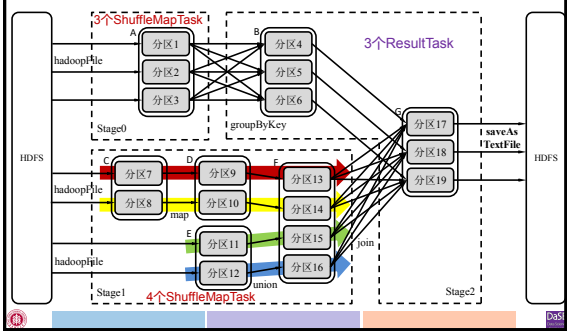

大纲

55

- 设计思想
- 体系架构
- 工作原理
  - DAG Stage划分
  - Stage内部数据交换
  - Stage之间数据交换
  - 应用、作业与任务
- 容错机制

Stage之间的特点

56

- 所有依赖关系都是宽依赖，不可以实现pipeline方式进行数据传输，只能Shuffle

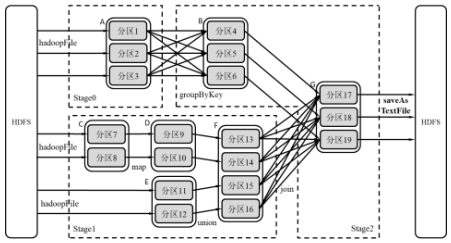

Stage之间的Shuffle

57

- Stage之间的数据交换需要进行Shuffle，该过程与MapReduce中的Shuffle类似
- Shuffle过程可能发生在两个ShuffleMapStage之间，或者ShuffleMapStage与ResultStage之间
- 从Task的层面来看，该过程表现为两组ShuffleMapTask之间，或一组ShuffleMapTask与一组ResultTask之间的数据交换

Spark Shuffle

58

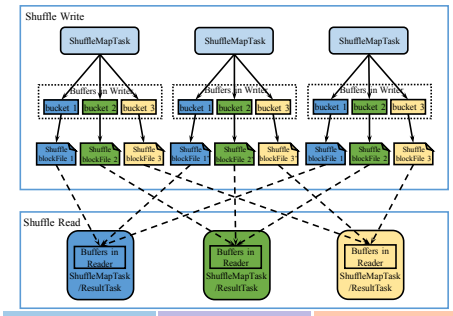

Shuffle Write vs. Shuffle Read

59

- 在Shuffle Write阶段，ShuffleMapTask需要将输出RDD的记录按照partition函数划分到相应的bucket当中并物化到本地磁盘形成ShuffleblockFile，之后才可以在Shuffle Read阶段被拉取
- 在Shuffle Read阶段，ShuffleMapTask或ResultTask根据partiton函数读取相应的ShuffleblockFile，存入buffer并进行继续后续的计算

Shuffle vs. Pipeline

60

- Stage之间：Shuffle
- Stage内部：Pipeline

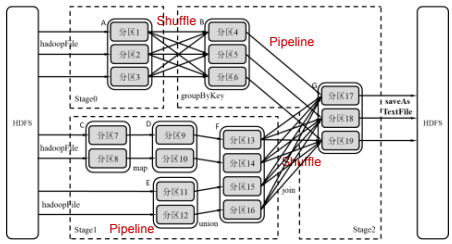

大纲

61

- 设计思想
- 体系架构
- 工作原理
  - DAG Stage划分
  - Stage内部数据交换
  - Stage之间数据交换
  - 应用、作业与任务
- 容错机制

应用、作业与任务

62

- Application：用户编写的Spark应用程序
- Job：一个Job包含多个RDD及作用于相应RDD转换操作，其中最后一个为action
- Stage：一个Job会分为多组Task，每组Task被称为Stage，或者也被称为TaskSet
  - Job的基本调度单位
  - 代表了一组关联的、相互之间没有Shuffle依赖关系的任务组成的任务集
- Task：运行在Executor上的工作单元

应用、作业与任务

63

- 逻辑执行角度
  - 一个Application=一个或多个DAG
  - 一个DAG=一个或多个Stage
  - 一个Stage=若干窄依赖的**RDD操作**
- 物理执行角度
  - 一个Application=一个或多个Job
  - 一个Job=一个或多个TaskSet
  - 一个TaskSet=多个没有Shuffle关系的**Task**

Job=DAG

Stage=TaskSet

逻辑概念与物理概念

64

逻辑		物理
Application	DAG	Job
	Stage	TaskSet
	Operator	Task

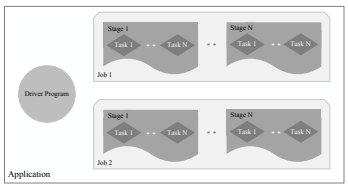

Spark vs. MapReduce

65

- 应用与作业

名称	MapReduce	Spark
应用	Job	Application
作业		Job/DAG

大纲

66

- 设计思想
- 体系架构
- 工作原理
- 容错机制

故障类型

67

- Master故障：ZooKeeper配置多个Master
- Worker故障
- Executor故障
- Driver故障：重启

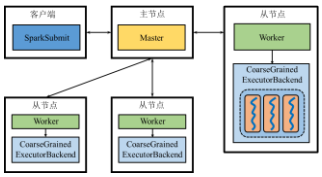

大纲

68

- 设计思想
- 体系架构
- 工作原理
- 容错机制
  - RDD持久化
  - 故障恢复
  - 检查点

RDD存储机制

69

- RDD提供的持久化（缓存）接口
  - persist()：对一个RDD标记为持久化
    - 接受StorageLevel类型参数，可配置各种级别
    - 持久化后的RDD将会被保留在工作节点的中被后面的行动操作重复使用
  - cache()
    - 相当于persist(MEMORY_ONLY)
  - 可以使用unpersist()方法手动地把持久化的RDD从缓存中移除
- 问题：没有标记持久化的RDD会怎样？

持久化举例

70

```
scala> val list = List("Hadoop","Spark","Hive")
list: List[String] = List(Hadoop, Spark, Hive)
scala> val rdd = sc.parallelize(list)
rdd: org.apache.spark.rdd.RDD[String] = ParallelCollectionRDD[22] at
parallelize at <console>:29
scala> rdd.cache() //会调用persist(MEMORY_ONLY)，但是，语句执行到这
里，并不会缓存rdd，因为这时rdd还没有被计算生成
scala> println(rdd.count()) //第一次行动操作，触发一次真正从头到尾的计算，
这时上面的rdd.cache()才会被执行，把这个rdd放到缓存中
3
scala> println(rdd.collect().mkString(",")) //第二次行动操作，不需要触发从头
到尾的计算，只需要重复使用上面缓存中的rdd
Hadoop,Spark,Hive
```

RDD存储机制

71

- Storage level
  - MEMORY_ONLY
  - MEMORY_AND_DISK
  - MEMORY_ONLY_SER
  - MEMORY_AND_DISK_SER
  - DISK_ONLY
  - MEMORY_ONLY_2, MEMORY_AND_DISK_2
  - OFF_HEAP (experimental)

RDD存储机制（续）

72

- persist(*)
  - MEMORY_ONLY：在JVM中缓存存储Java的对象。如果内存不足，直接丢弃某些partition
  - MEMORY_AND_DISK：在JVM中缓存Java的对象。如果内存不足，则将某些partitions写入到磁盘中
  - MEMORY_ONLY_SER：在内存为每个partition存储一个byte数组，数组内容为当前partition中Java对象的序列化结果
  - MEMORY_AND_DISK_SER：与MEMORY_AND_DISK类似，但是每个partition存储的是Java对象序列化后组成的byte数组。

RDD的存储机制（续）

73

- persist(*)
  - DISK_ONLY: 将每个partition的数据序列化到磁盘中
  - MEMORY_ONLY_2, MEMORY_AND_DISK_2: 与名字中类型对应，但是每个partition备份到两台机器上
  - OFF_HEAP：
    - RDD的数据被序列化后存储在Tachyon中
    - Tachyon决定内存块的替换
    - 与MEMORY_ONLY_SER对比
      - 数据与executor的分离，避免某个executor失效导致当前节点上数据的丢失
      - executor之间能够共享内存
      - 降低垃圾回收的代价，减少executor的运行空间

大纲

74

- 设计思想
- 体系架构
- 工作原理
- 容错机制
  - RDD持久化
  - 故障恢复
  - 检查点

Lineage机制

75

- RDD dependencies

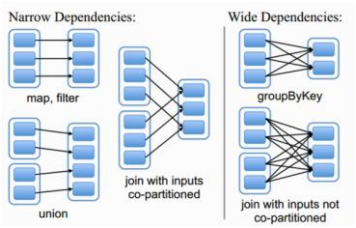

Lineage机制

76

- 红色部分丢失，需重算紫色部分

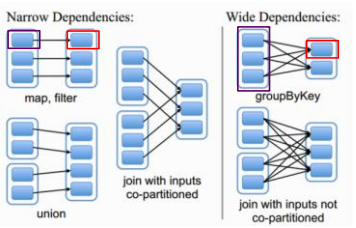

Lineage机制

77

- 窄依赖(narrow dependency)
  - 执行某个partition时，检查父亲RDD对应的partition是否存在
    - 存在，即可执行当前RDD对应的操作
    - 不存在，则重构父亲RDD对应的partition
- 宽依赖(wide dependency)
  - 执行某个partition时，检查父亲RDD对应的partition是否存在
    - 存在，即可执行当前RDD对应的操作
    - 不存在，则重构整个父亲RDD

基于RDD Lineage恢复

78

- 利用RDD Lineage的故障恢复
  - 重新计算丢失分区
  - 重算过程在不同节点之间可以并行
- 与数据库恢复的比较
  - RDD Lineage：记录粗粒度的操作
  - 数据复制或者日志：记录细粒度的操作

大纲

79

- 设计思想
- 体系架构
- 工作原理
- 容错机制
  - RDD持久化
  - 故障恢复
  - 检查点

检查点机制

80

- 前述机制的不足之处
  - Lineage可能非常长
  - RDD持久化机制保存到集群内机器的磁盘，并不完全可靠
- 检查点机制将RDD写入外部可靠的（本身具有容错机制）分布式文件系统，例如HDFS
  - 在实现层面，写检查点的过程是一个独立job，在用户作业结束后运行

课后阅读

81

- 论文
  - Zaharia, M., Chowdhury, M., Franklin, M. J., Shenker, S., & Stoica, I. (2010). Spark : Cluster Computing with Working Sets. In HotCloud (pp. 1–7).
  - Zaharia, M., Chowdhury, M., Das, T., Dave, A., Ma, J., Mccauley, M., … Stoica, I. (2012). Resilient Distributed Datasets : A Fault-Tolerant Abstraction for In-Memory Cluster Computing. In NSDI (pp. 15–28).

本讲小节

82

- 设计思想
- 体系架构
- 工作原理
- 容错机制

谢谢！Q&A