第十一讲 流计算系统
Spark Streaming

徐 辰
cxu@dase.ecnu.edu.cn
華東師範大學

Making an elephant dancing

大纲

- 设计思想
  - 连续处理 vs. 微批处理
  - 数据模型
  - 计算模型
- 体系架构
- 工作原理
- 容错机制
- 编程实例

连续处理(Continuous processing)

- Existing streaming systems have a record-at-a-time processing model
  - Each node has mutable state
  - For each record, update state and send new records

- State is lost if node dies!
- Making stateful stream processing be fault-tolerant is challenging

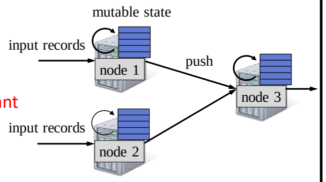

微批处理(Micro-batch processing)

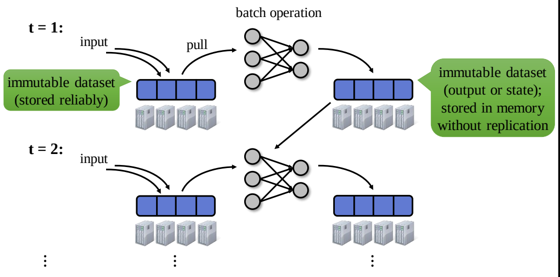
batch operation
t = 1:
input
pull
immutable dataset (stored reliably)
immutable dataset (output or state); stored in memory without replication
t = 2:
input

What is Spark Streaming?

- Extends Spark for doing large scale stream processing

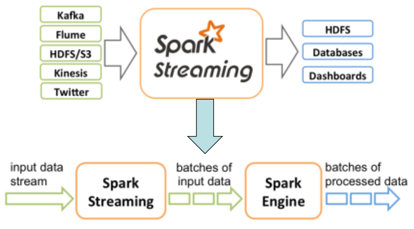

Basic Idea

7

- Break input data streams into **batches**
- Derive an **RDD** per batch
- **Emulate (模拟)** a **continuous** execution by scheduling each consecutive **RDD** operation (as its own application).

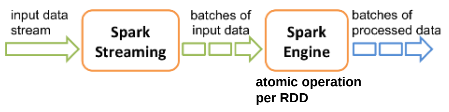

Spark + MicroBatch

8

Run a streaming computation as a series of very small, deterministic batch jobs

- Chop up the live stream into batches of X seconds
- Spark treats each batch of data as RDDs and processes them using RDD operations
- Finally, the processed results of the RDD operations are returned in batches

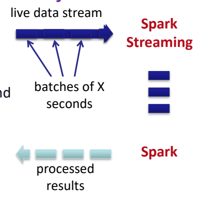

大纲

9

- 设计思想
  - 连续处理 vs. 微批处理
  - 数据模型
  - 计算模型
- 体系架构
- 工作原理
- 容错机制
- 编程实例

流数据的离散化

10

- 在Storm的数据模型中，我们将流数据看作一系列连续的元组
- Spark Streaming将连续的流数据切片，即离散化，生成一系列小块数据

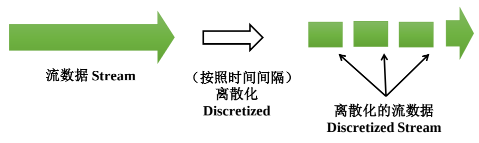
流数据 Stream
（按照时间间隔）离散化 Discretized
离散化的流数据 Discretized Stream

DStream数据模型

11

- 按照数据到来的时间间隔将连续的数据流离散化
- 得到的每一小批数据都是独立的RDD，一组RDD序列抽象为流数据的DStream

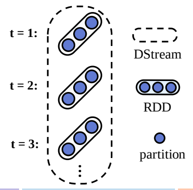

DStream数据模型

12

- 对输入数据流进行切割
  - 根据用户指定的时间间隔对数据进行切割
  - DStream维护一系列RDD的信息

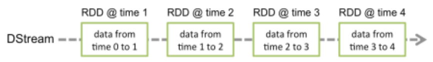

大纲

- 设计思想
  - 连续处理 vs. 微批处理
  - 数据模型
  - 计算模型
- 体系架构
- 工作原理
- 容错机制
- 编程实例

逻辑计算模型

- Operator DAG：与RDD的operator类似

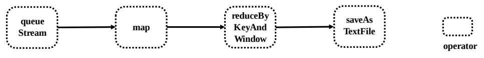

- DStream Lineage：借用RDD Lineage的概念

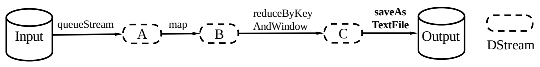

物理计算模型：Operator DAG

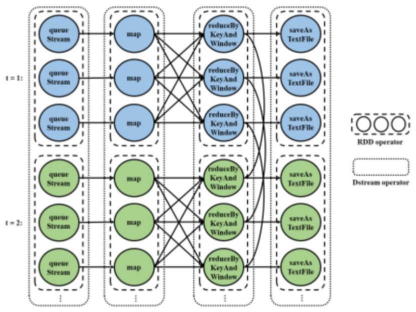

物理计算模型：DStream Lineage

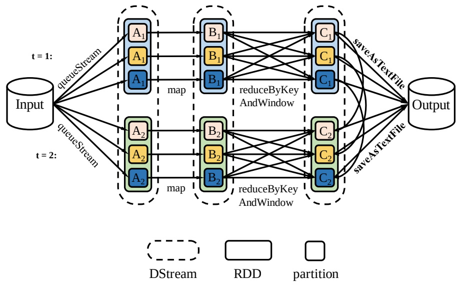

大纲

- 设计思想
- 体系架构
  - 架构图
  - 应用程序执行流程
- 工作原理
- 容错机制
- 编程实例

架构图

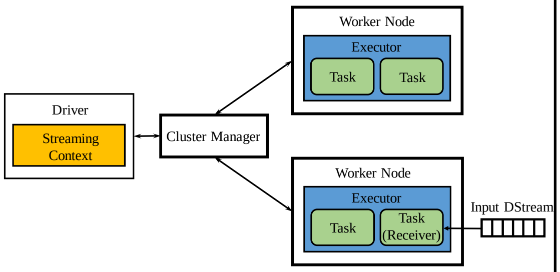

工作部件

- Driver: Spark Streaming对SparkContext进行了扩充，构造了StreamingContext，用于管理流计算的元信息。
- Executor: Executor中作为Receiver的某些task，负责从外部数据源源源不断的获取流数据，这和spark批处理读取数据的方式是不同的。

大纲

- 设计思想
- 体系架构
  - 架构图
  - 应用程序执行流程
- 工作原理
- 容错机制
- 编程实例

应用程序执行流程

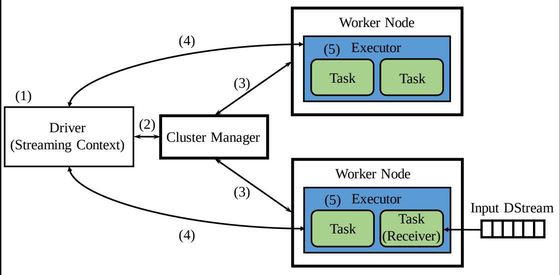

应用程序执行流程

1. 启动Driver，以Standalone模式为例
   - 如果使用Client部署方式，客户端端直接启动Driver，并向Master注册。
   - 如果使用Cluster部署方式，客户端将应用程序提交给Master，由Master选择一个Worker启动Driver进程(DriverWrapper)。
2. 构建基本运行环境，即由Driver创建StreamingContext，向Cluster Manager进行资源申请，并由Driver进行任务分配和监控

应用程序执行流程（续）

3. Cluster Manager通知工作节点启动Executor进程，该进程内部以多线程方式运行任务
4. Executor进程向Driver注册
5. StreamingContext构建关于RDD转换的DAG，从而交给Executor进程中的线程来执行任务。

大纲

- 设计思想
- 体系架构
- 工作原理
- 容错机制
- 编程实例

工作过程

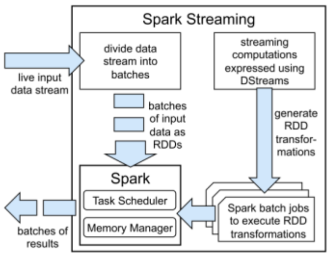
Spark Streaming
divide data stream into batches
streaming computations expressed using DStreams
live input data stream
batches of input data as RDDs
generate RDD transformations
Spark
Task Scheduler
Memory Manager
Spark batch jobs to execute RDD transformations
batches of results

大纲

- 设计思想
- 体系架构
- 工作原理
  - 数据输入
  - 数据转换
  - 数据输出
- 容错机制
- 编程实例

流数据读取

- 从外部数据源直接获取数据
  - 从socket端口获取网络数据
  - 接收外部传感器产生的数据
  - ……
- 从外部存储系统周期性地读取数据
  - 数据源将数据存入HDFS
  - 数据源将数据存入Kafaka
  - ……

常用数据输入接口

- socketTextStream
- fileStream
- textFileStream
- queueStream

https://spark.apache.org/docs/latest/streaming-programming-guide.html#input-dstreams-and-receivers

大纲

- 设计思想
- 体系架构
- 工作原理
  - 数据输入
  - 数据转换
  - 数据输出
- 容错机制
- 编程实例

数据转换

- DStream转换操作
  - map(func)
  - flatMap(func)
  - filter(func)
  - repartition(numPartitions)
  - union(otherStream) .
  - count()
  - reduce(func)
  - countByValue()
  - reduceByKey(func, [numTasks])
  - join(otherStream, [numTasks])
  - cogroup(otherStream, [numTasks])
- 直接使用RDD转换操作
  - Transform(func)

https://spark.apache.org/docs/latest/streaming-programming-guide.html#transformations-on-dstreams

Transform

- Transform
  - 允许用户在DStream的每个RDD上执行DStream为支持的RDD操作
  - 例如：DStream与RDD之间的join

```
val spamInfoRDD = ssc.sparkContext.newAPIHadoopRDD(...)
// RDD containing spam information

val cleanedDStream = wordCounts.transform { rdd =>
  rdd.join(spamInfoRDD).filter(...)
// join data stream with spam information to do data cleaning
  ...
}
```

数据转换

- window(windowLength, slideInterval)
- countByWindow(windowLength, slideInterval)
- reduceByWindow(func, windowLength, slideInterval)
- reduceByKeyAndWindow(func, windowLength, slideInterval, [numTasks])
- reduceByKeyAndWindow(func, invFunc, windowLength, slideInterval, [numTasks])
- countByValueAndWindow(windowLength, slideInterval, [numTasks])

窗口操作

- updateStateByKey(func)

滑动窗口

- 用户可以指定窗口时间间隔，窗口大小

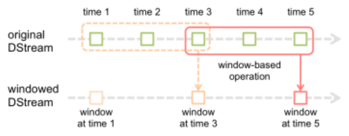

```
val tweets = ssc.twitterStream()
val hashTags = tweets.flatMap (status => getTags(status))
val tagCounts = hashTags.window(Minutes(1), Seconds(5)).countByValue()
```

window operation | window length | sliding interval

DStream窗口操作

- window(windowLength, slideInterval)
  - window(3,2)即实现了前一页的功能
- countByWindow(windowLength, slideInterval)
  - 统计每个窗口内元素的个数
- countByValueAndWindow(windowLength, slideInterval, [numTasks])
  - 统计每个窗口内每个key出现的频率
- reduceByKeyAndWindow(func, windowLength, slideInterval, [numTasks])
  - 对每个窗口构成的数据执行reducebykey操作
- reduceByKeyAndWindow(func, invFunc, windowLength, slideInterval, [numTasks])
  - 通过提供的invFunc提供流数据"逆操作",从而达到更高的效率

窗口逆函数

- 增量式窗口操作：t+3的sliding counts按照左边方式得出，t+4的sliding counts右边方式得出

每次重新计算当前5个时间单位构成的窗口中的所有数据

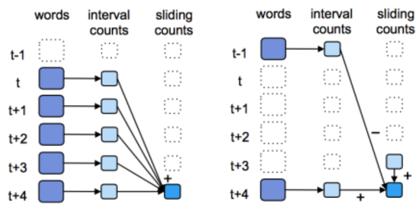

Window Types

Time-based vs.
Count-based window

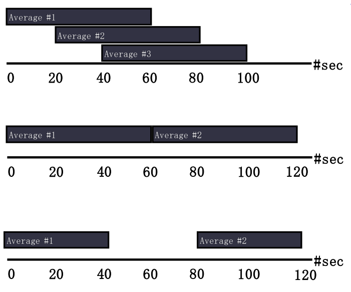

Sliding *range > slide*
滑动窗口

Tumbling *range = slide*
滚动窗口

Jumping *range < slide*
跳跃窗口

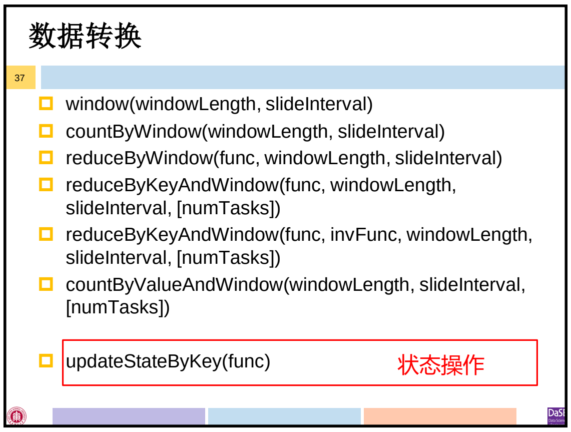

数据转换

37

- window(windowLength, slideInterval)
- countByWindow(windowLength, slideInterval)
- reduceByWindow(func, windowLength, slideInterval)
- reduceByKeyAndWindow(func, windowLength, slideInterval, [numTasks])
- reduceByKeyAndWindow(func, invFunc, windowLength, slideInterval, [numTasks])
- countByValueAndWindow(windowLength, slideInterval, [numTasks])

- updateStateByKey(func) 状态操作

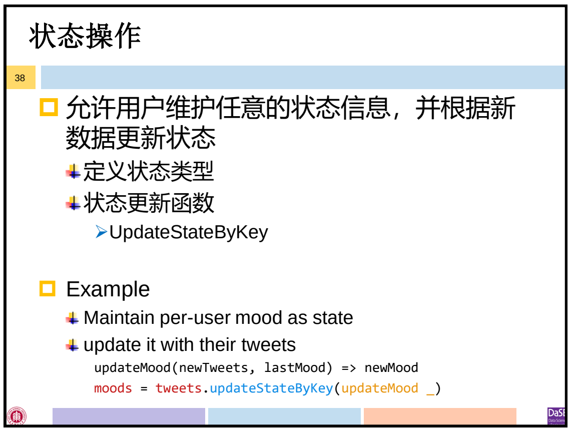

状态操作

38

- 允许用户维护任意的状态信息，并根据新数据更新状态
  - 定义状态类型
  - 状态更新函数
    - UpdateStateByKey

- Example
  - Maintain per-user mood as state
  - update it with their tweets

```
updateMood(newTweets, lastMood) => newMood
moods = tweets.updateStateByKey(updateMood _)
```

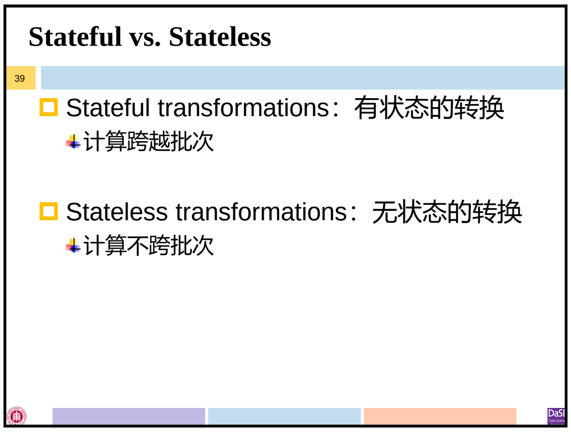

Stateful vs. Stateless

39

- Stateful transformations：有状态的转换
  - 计算跨越批次

- Stateless transformations：无状态的转换
  - 计算不跨批次

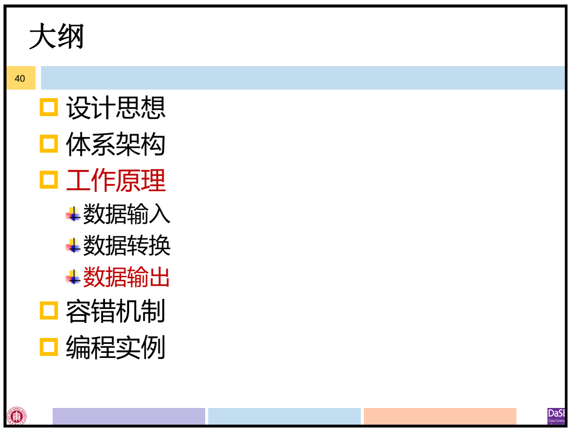

大纲

40

- 设计思想
- 体系架构
- 工作原理
  - 数据输入
  - 数据转换
  - 数据输出
- 容错机制
- 编程实例

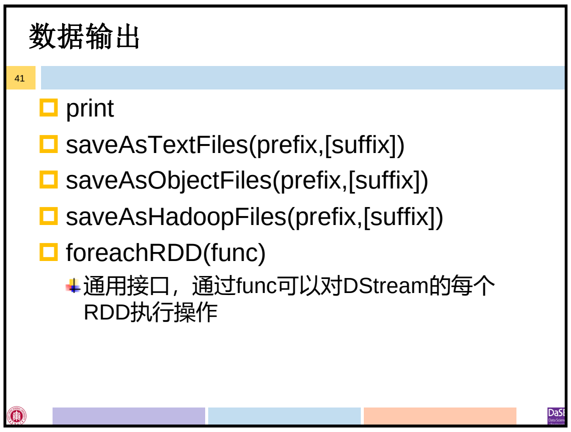

数据输出

41

- print
- saveAsTextFiles(prefix,[suffix])
- saveAsObjectFiles(prefix,[suffix])
- saveAsHadoopFiles(prefix,[suffix])
- foreachRDD(func)
  - 通用接口，通过func可以对DStream的每个RDD执行操作

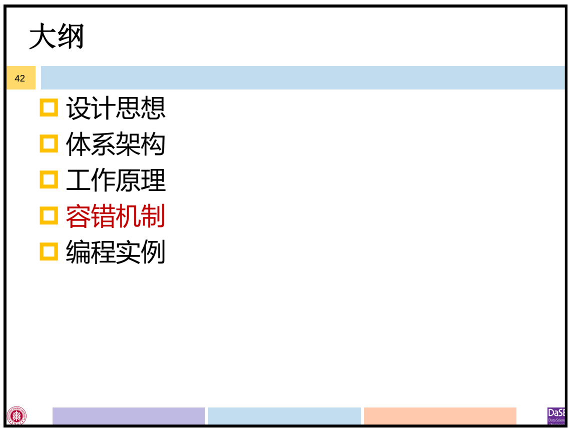

大纲

42

- 设计思想
- 体系架构
- 工作原理
- 容错机制
- 编程实例

故障类型

43

- Cluster Manager故障：不考虑
- Executor(Worker)故障
  - 不含Receiver
  - 含有Receiver
- Driver故障

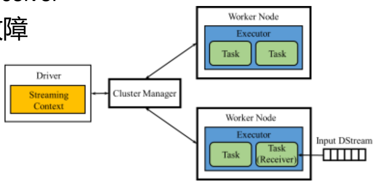

不含Receiver的Executor故障

44

- RDDs remember the operations that created them
- Batches of input data are replicated in memory for fault-tolerance
- Data lost due to worker failure, can be recomputed from replicated input data
- All transformed data is fault-tolerant, and exactly-once transformations

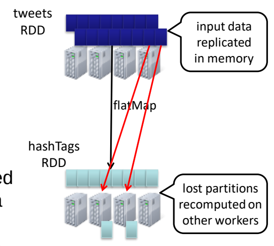
tweets RDD
input data replicated in memory
flatMap
hashTags RDD
lost partitions recomputed on other workers

故障类型

45

- Cluster Manager故障：不考虑
- Executor(Worker)故障
  - 不含Receiver
  - 含有Receiver
- Driver故障

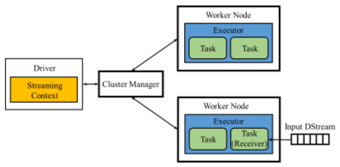

大纲

46

- 设计思想
- 体系架构
- 工作原理
- 容错机制
  - 日志与检查点
  - 故障恢复
- 编程实例

日志

47

- 日志：标记哪些接收到数据已经做了备份
  - Receiver日志
  - Driver日志

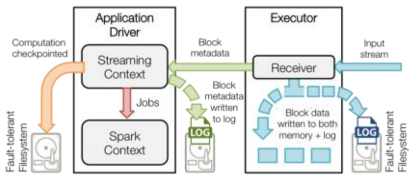

检查点

48

- 检查点：计算的结果
  - 数据检查点
    - 将有状态转换操作生成的RDD周期性地写入检查点
  - 元数据检查点
    - 配置信息：创建spark streaming应用程序的配置信息
    - DStream操作信息：定义了应用程序计算逻辑的DStream操作的信息
    - 未处理的batch信息：那些正在排队的作业中还没处理的batch信息

大纲

- 设计思想
- 体系架构
- 工作原理
- 容错机制
  - 日志与检查点
  - 故障恢复
- 编程实例

故障恢复

- Executor(Worker)故障恢复

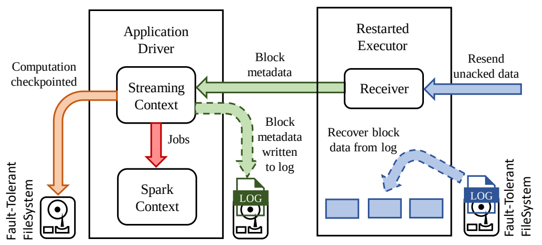

故障恢复

- Driver故障恢复

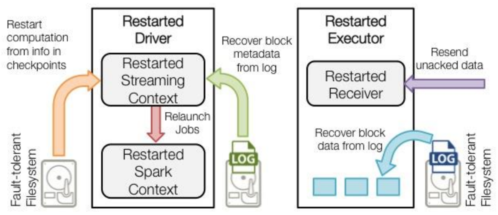
Restart computation from info in checkpoints
Fault-tolerant Filesystem
Restarted Driver
Restarted Streaming Context
Relaunch Jobs
Restarted Spark Context
Recover block metadata from log
LOG
Restarted Executor
Restarted Receiver
Resend unacked data
Recover block data from log
LOG
Fault-tolerant Filesystem

容错语义

- Receiving the data: *at-least or exactly once*
  - The data is received from sources using Receivers or others.
- Transforming the data: *exactly once*
  - The received data is transformed using DStream and RDD transformations.
- Pushing out the data: *at-least or exactly once*
  - The final transformed data is pushed out to external systems like file systems, databases, dashboards, etc.

大纲

- 设计思想
- 体系架构
- 工作原理
- 容错机制
- 编程实例

Spark API

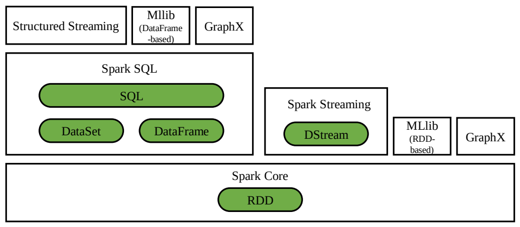

Spark Streaming程序框架

55

1.通过创建输入DStream来定义输入源

2.通过对DStream应用转换操作和输出操作来定义流计算

3.用streamingContext.start()来开始接收数据和处理流程

4.通过streamingContext.awaitTermination()方法来等待处理结束（手动结束或因为错误而结束）

5.可以通过streamingContext.stop()来手动结束流计算进程

Example – Get hashtags from Twitter

56

```
val tweets = ssc.twitterStream()
```

DStream: a sequence of RDDs representing a stream of data

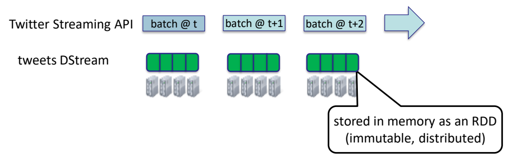

Example – Get hashtags from Twitter

57

```
val tweets = ssc.twitterStream()
val hashTags = tweets.flatMap (status => getTags(status))
```

new DStream

transformation: modify data in one DStream to create another DStream

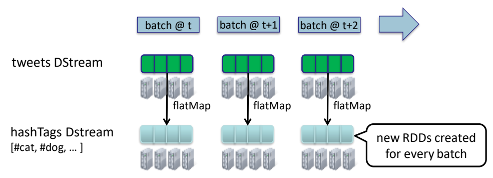

Example – Get hashtags from Twitter

58

```
val tweets = ssc.twitterStream()
val hashTags = tweets.flatMap (status => getTags(status))
         .saveAsHadoopFiles("hdfs://...")
```

output operation: to push data to external storage

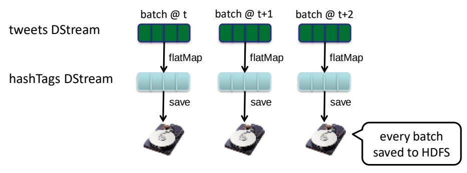

Example – Get hashtags from Twitter

59

```
val tweets = ssc.twitterStream()
val hashTags = tweets.flatMap (status => getTags(status))
         .foreach(hashTagRDD => { ... })
```

foreach: do whatever you want with the processed data

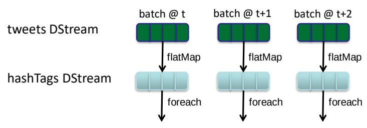

Write to database, update analytics UI, do whatever you want

Java Example

60

Scala

```
val tweets = ssc.twitterStream()
val hashTags = tweets.flatMap (status => getTags(status))
hashTags.saveAsHadoopFiles("hdfs://...")
```

Java

```
JavaDStream<Status> tweets = ssc.twitterStream()
JavaDstream<String> hashTags = tweets.flatMap(new
                                        Function<...> {  })
hashTags.saveAsHadoopFiles("hdfs://...")
```

Function object

Window-based Transformations

61

```
val tweets = ssc.twitterStream()
val hashTags = tweets.flatMap (status => getTags(status))
val tagCounts = hashTags.window(Minutes(1), Seconds(5)).countByValue()
```

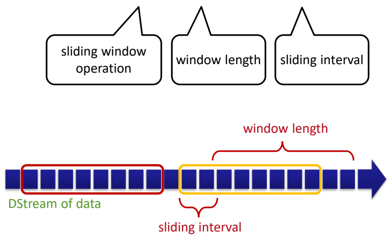

课后阅读

62

- 论文
  - Zaharia, M., Das, T., Li, H., Hunter, T., Shenker, S., & Stoica, I. (2013). Discretized Streams: Fault-Tolerant Streaming Computation at Scale. In SOSP (pp. 423–438).

本讲小结

63

- 设计思想
- 体系架构
- 工作原理
- 容错机制
- 编程实例

谢谢！Q&A

Reminder：本科生

64

- 实验报告提交
  - Spark部署与编程：2019年11月17日 23:59
  - Storm部署与编程：2019年11月24日 23:59
- 作业提交
  - Storm：2019年11月20日 23:59

Reminder：研究生

65

- 选择上课所讲述之外的系统，从设计思想、体系结构、工作原理、容错机制等角度与所学系统进行对比分析，谈谈你的理解
- 格式、命名方式等要求详见大夏学堂
- 提交方式：
  - **2019.12.31**前发送到dasebigdata@163.com