

第十章 最优性条件和对偶理论

第 35 讲 Lagrange 对偶

黄定江

DaSE @ ECNU

djhuang@dase.ecnu.edu.cn

1 10.1 Lagrange 对偶函数

- Lagrange
- Lagrange 对偶函数
- 最优值的下界
- 通过线性逼近来理解
- Lagrange 对偶函数和共轭函数

2 10.2 常见的对偶函数

- 线性方程组的最小二乘解
- 标准形式的线性规划
- 双向划分问题
- 等式约束条件下的范数极小

1 10.1 Lagrange 对偶函数

- Lagrange
- Lagrange 对偶函数
- 最优值的下界
- 通过线性逼近来理解
- Lagrange 对偶函数和共轭函数

2 10.2 常见的对偶函数

- 线性方程组的最小二乘解
- 标准形式的线性规划
- 双向划分问题
- 等式约束条件下的范数极小

10.1.1 Lagrange

考虑标准形式的优化问题 (不一定是凸的)

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m \\ & && h_i(x) = 0, \quad i = 1, \dots, p \end{aligned} \tag{1}$$

自变量 $x \in R^n$, 定义域 $\mathcal{D} = \bigcap_{i=1}^m \text{dom } f_i \cap \bigcap_{i=1}^p \text{dom } h_i$, 最优值 p^*

10.1.1 Lagrange

Lagrange 函数: $L: \mathcal{D} \times R^m \times R^p \rightarrow R$ 为

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x)$$

其中定义域为 $\text{dom } L = \mathcal{D} \times R^m \times R^p$

- Lagrange 对偶的基本思想: 添加约束条件的加权和, 得到增广的目标函数
- λ_i 称为第 i 个不等式约束 $f_i(x) \leq 0$ 对应的 **Lagrange 乘子**
- ν_i 称为第 i 个等式约束 $h_i(x) = 0$ 对应的 **Lagrange 乘子**
- 向量 λ 和 ν 称为对偶变量或者问题 (1) 的 **Lagrange 乘子向量**

10.1.2 Lagrange 对偶函数

Lagrange 对偶函数 (或对偶函数) $g: R^m \times R^p \rightarrow R$ 为 Lagrange 函数关于 x 取得的最小值: 即对 $\lambda \in R^m, \nu \in R^p$, 有

$$g(\lambda, \nu) = \inf_{x \in \mathcal{D}} L(x, \lambda, \nu) = \inf_{x \in \mathcal{D}} \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x) \right)$$

- 函数关于 x 无下界, 则对偶函数取值为 $-\infty$
- 对偶函数是一族关于 (λ, ν) 的仿射函数的逐点下确界, 所以即使原问题 (1) 非凸, 对偶函数也是凹函数

10.1.3 最优值的下界

对偶问题构成了原问题 (1) 最优值 p^* 的下界：即对任意 $\lambda \geq 0$ 和 ν ，下式成立

$$g(\lambda, \nu) \leq p^* \quad (2)$$

证明.

设 \tilde{x} 是原问题 (1) 的一个可行点，即 $f_i(\tilde{x}) \leq 0$ 且 $h_i(\tilde{x}) = 0$ 。根据假设， $\lambda \geq 0$ ，有

$$\sum_{i=1}^m \lambda_i f_i(\tilde{x}) + \sum_{i=1}^p \nu_i h_i(\tilde{x}) \leq 0$$

左边第一项非正，第二项为零



10.1.3 最优值的下界

Proof.Cont.

根据上述不等式, 有

$$L(\tilde{x}, \lambda, \nu) = f_0(\tilde{x}) + \sum_{i=1}^m \lambda_i f_i(\tilde{x}) + \sum_{i=1}^p \nu_i h_i(\tilde{x}) \leq f_0(\tilde{x}).$$

因此

$$g(\lambda, \nu) = \inf_{x \in \mathcal{D}} L(x, \lambda, \nu) \leq L(\tilde{x}, \lambda, \nu) \leq f_0(\tilde{x})$$

由于每一个可行点 \tilde{x} 都满足 $g(\lambda, \nu) \leq f_0(\tilde{x})$, 因此 $g(\lambda, \nu) \leq p^*$ 成立 □

10.1.3 最优值的下界

- 针对 $x \in R$ 和具有一个不等式约束的某简单问题, 图 (1) 描述了式 (2) 所给出的下界
- 虽然不等式 (2) 成立, 但当 $g(\lambda, v) = -\infty$ 时其意义不大
- 只有当 $\lambda \geq 0$ 且 $((\lambda, v)) \in \text{dom } g$ 时, $g(\lambda, v)$ 是对偶可行的

10.1.3 最优值的下界




图 1: 对偶可行点给出的下界。实线表示目标函数 f_0 , 虚线表示约束函数 f_1 。可行集 $[-0.46, 0.46]$, 如图中两条垂直点线所示。最优点 $x^* = -0.46$, 最优值 $p^* = 1.54$ 。点线表示一系列 Lagrange 函数 $L(x, \lambda)$, 其中 $\lambda = 0.1, 0.2, \dots, 1.0$ 。每个 Lagrange 函数都有一个极小值, 均小于原问题最优目标值 p^* , 这是因为在可行集上有 $L(x, \lambda) \leq f_0(x)$ 。

10.1.3 最优值的下界




图 2: 图1中问题的对偶函数 g 。函数 f_0 和 f_1 都不是凸函数，但是对偶函数是凹函数。水平虚线是原问题的最优函数值 p^* 。

10.1.4 通过线性逼近来理解

通过对集合 $\{0\}$ 和 $-R_+$ 的示性函数进行线性逼近来理解 Lagrange 函数和其给出下界的性质。将原问题 (1) 重新描述为一个无约束问题：

$$\text{minimize} \quad f_0(x) + \sum_{i=1}^m I_-(f_i(x)) + \sum_{i=1}^p I_0(h_i(x)) \quad (3)$$

其中, $I_- : R \rightarrow R$ 是非正实数集的示性函数

$$I_-(u) = \begin{cases} 0 & u \leq 0 \\ \infty & u > 0 \end{cases}$$

- 在表达式 (3) 中, 函数 $I_-(u)$ 可以理解为对约束函数值 $u = f_i(x)$ 的一种恼怒或不满: 如果 $f_i(x) \leq 0$, $I_-(u)$ 为零, 如果 $f_i(x) > 0$, $I_-(u)$ 为 ∞
- 可以认为函数 I_- 是一个“砖墙式”或“无限强硬”的不满意方程; 即随着函数 $f_i(x)$ 从非正数变为正数, 不满意度从 0 升到无穷大

10.1.4 通过线性逼近来理解

设在表达式 (3) 中, 用线性函数 $\lambda_i u$ 替代函数 $I_-(u)$, 其中 $\lambda_i \geq 0$, 用函数 $v_i u$ 替代 $I_0(u)$ 。则目标函数变为 Lagrange 函数 $L(x, \lambda, v)$, 且对偶函数值 $g(\lambda, v)$ 是问题 (4) 的最优值

$$\text{minimize} \quad L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x) \quad (4)$$

- 表达式 (4) 中, 用线性或者“软”的不满意函数替换了函数 I_- 和 I_0 , 如果 $f_i(x) = 0$, 不满意度为 0, 当 $f_i(x) > 0$ 时, 不满意度大于 0 (假设 $\lambda_i > 0$), 随着约束“越来越被违背”, 我们越来越不满意
- 用线性函数 $\lambda_i u$ 去逼近 $I_-(u)$ 远远不够, 但线性函数可看成是示性函数的一个下估计, 因为对任意 u , 有 $\lambda_i u \leq I_-(u)$ 和 $v_i u \leq I_0(u)$, 随之可得到, 对偶函数是原问题最有函数值的一个下界

10.1.5 Lagrange 对偶函数和共轭函数

回忆函数 $f: R^n \rightarrow R$ 的共轭函数 f^* 为

$$f^*(y) = \sup_{x \in \text{dom } f} (y^T x - f(x))$$

考虑问题

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && Ax \leq b, \quad Cx = d \end{aligned} \tag{5}$$

利用函数 f_0 的共轭函数, 其对偶函数为

$$\begin{aligned} g(\lambda, \nu) &= \inf_x (f_0(x) + \lambda^T (Ax - b) + \nu^T (Cx - d)) \\ &= -b^T \lambda - d^T \nu + \inf_x (f_0(x) + (A^T \lambda + C^T \nu)^T x) \\ &= -b^T \lambda - d^T \nu - f_0^*(-A^T \lambda - C^T \nu) \end{aligned} \tag{6}$$

函数 g 的定义域 $\text{dom } g = \{(\lambda, v) \mid -A^T \lambda - C^T v \in \text{dom } f_0^*\}$

等式约束条件下的范数极小化

例 1

考虑问题

$$\begin{array}{ll} \text{minimize} & \|x\| \\ \text{subject to} & Ax = b \end{array} \quad (7)$$

其中 $\|\cdot\|$ 是任意范数。求其对偶函数

等式约束条件下的范数极小化

$f_0 = \|\cdot\|$ 的共轭函数为

$$f_0^*(y) = \begin{cases} 0 & \|y\|_* \leq 1 \\ \infty & \text{其他情况} \end{cases}$$

可以看出此函数是对偶范数单位球的示性函数。利用结论 (6) 得到问题 (7) 的对偶函数为

$$g(v) = -b^T v - f_0^*(-A^T v) = \begin{cases} -b^T v & \|A^T v\|_* \leq 1 \\ -\infty & \text{其他情况} \end{cases}$$

熵的最大化

例 2

考虑问题

$$\begin{aligned} & \text{minimize} && f_0(x) = \sum_{i=1}^n x_i \log x_i \\ & \text{subject to} && Ax \leq b, \quad \mathbf{1}^T x = 1 \end{aligned} \tag{8}$$

其中 $\text{dom } f_0 = R_{++}^n$ 。求其对偶函数

熵的最大化

关于实变量 u 的负熵函数 $u \log u$ 的共轭函数是 e^{v-1} 。由于函数 f_0 是不同变量的负熵函数的和，其共轭函数为

$$f_0^*(y) = \sum_{i=1}^n e^{y_i-1}$$

其定义域为 $\text{dom } f_0^* = R^n$ 。根据前述结论 (6)，问题 (8) 的对偶函数为

$$g(\lambda, v) = -b^T \lambda - v - \sum_{i=1}^n e^{-a_i^T \lambda - v - 1} = -b^T \lambda - v - e^{-v-1} \sum_{i=1}^n e^{-a_i^T \lambda}$$

其中 a_i 是矩阵 A 的第 i 列向量

1 10.1 Lagrange 对偶函数

- Lagrange
- Lagrange 对偶函数
- 最优值的下界
- 通过线性逼近来理解
- Lagrange 对偶函数和共轭函数

2 10.2 常见的对偶函数

- 线性方程组的最小二乘解
- 标准形式的线性规划
- 双向划分问题
- 等式约束条件下的范数极小

10.2.1 线性方程组的最小二乘解

例 3

考虑问题

$$\begin{array}{ll} \text{minimize} & x^T x \\ \text{subject to} & Ax = b \end{array} \quad (9)$$

其中 $A \in R^{p \times n}$ 。求其对偶函数

10.2.1 线性方程组的最小二乘解

此问题无不等式约束，有 p 个（线性）等式约束，其 Lagrange 函数为

$$L(x, \nu) = x^T x + \nu^T (Ax - b)$$

定义域为 $R^n \times R^p$ 。对偶函数为

$$g(\nu) = \inf_x L(x, \nu)$$

10.2.1 线性方程组的最小二乘解

因为 $L(x, \nu)$ 是 x 的二次凸函数, 可通过求解最优性条件得到函数的最小值

- L 关于 x 取极小值, 梯度为零:

$$\nabla_x L(x, \nu) = 2x + A^T \nu = 0 \implies x = -(1/2)A^T \nu$$

- 代入到 L 得到函数 g :

$$g(\nu) = L((-1/2)A^T \nu, \nu) = -(1/4)\nu^T A A^T \nu - b^T \nu$$

是关于 ν 的二次凹函数, 定义域为 R^p

最优值下界: 根据性质 (2), 对 $\forall \nu \in R^p$

$$p^* \geq -(1/4)\nu^T A A^T \nu - b^T \nu$$

10.2.2 标准形式的线性规划

例 4

考虑问题

$$\begin{array}{ll} \text{minimize} & c^T x \\ \text{subject to} & Ax = b, \quad x \geq 0 \end{array} \quad (10)$$

其中，不等式约束函数为 $f_i(x) = -x_i, i = 1, \dots, n$ 。求其对偶函数

10.2.2 标准形式的线性规划

为了推导 Lagrange 函数, 对 n 个不等式约束引入 Lagrange 乘子 λ_i , 对等式约束引入 Lagrange 乘子 ν_i , 得到

$$\begin{aligned} L(x, \lambda, \nu) &= c^T x - \sum_{i=1}^n \lambda_i x_i + \nu^T (Ax - b) \\ &= -b^T \nu + (c + A^T \nu - \lambda)^T x \end{aligned}$$

L 关于 x 线性, 因此对偶函数为

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu) = \begin{cases} -b^T \nu & A^T \nu - \lambda + c = 0 \\ -\infty & \text{其他情况} \end{cases}$$

g 在仿射域 $\{(\lambda, \nu) | A^T \nu - \lambda + c = 0\}$ 上是线性函数, 因此总体是凹函数

最优值下界: 如果 $A^T \nu + c \geq 0$, $p^* \geq -b^T \nu$

10.2.3 双向划分问题

例 5

考虑问题

$$\begin{aligned} & \text{minimize} && x^T W x \\ & \text{subject to} && x_i^2 = 1, \quad i = 1, \dots, n \end{aligned} \tag{11}$$

其中, $W \in S^n$ 。求其对偶函数

10.2.3 双向划分问题

- 这是一个非凸问题；可行集包含 2^n 个离散点
- 解释：可将 $\{1, \dots, n\}$ 划分为两个集合：

$$\{1, \dots, n\} = \{i \mid x_i = -1\} \cup \{i \mid x_i = 1\}$$

矩阵系数 W_{ij} 可以看成分量 i, j 在同一分区的成本， $-W_{ij}$ 可以看成分量 i, j 在不同分区内的成本。原问题中的目标函数是考虑分量间所有配件的成本，即寻找使得总成本最小的划分

10.2.3 双向划分问题

Lagrange 函数:

$$\begin{aligned} L(x, \nu) &= x^T W x + \sum_{i=1}^n \nu_i (x_i^2 - 1) \\ &= x^T (W + \text{diag}(\nu)) x - \mathbf{1}^T \nu \end{aligned}$$

对偶函数:

$$\begin{aligned} g(\nu) &= \inf_x (x^T W x + \sum_i \nu_i (x_i^2 - 1)) = \inf_x x^T (W + \text{diag}(\nu)) x - \mathbf{1}^T \nu \\ &= \begin{cases} -\mathbf{1}^T \nu & W + \text{diag}(\nu) \geq 0 \\ -\infty & \text{其他情况} \end{cases} \end{aligned}$$

最优值下界: 如果 $W + \text{diag}(\nu) \geq 0$, $p^* \geq -\mathbf{1}^T \nu = n\lambda_{\min}(W)$

10.2.4 等式约束条件下的范数极小化

例 6

考虑问题

$$\begin{array}{ll} \text{minimize} & \|x\| \\ \text{subject to} & Ax = b \end{array} \quad (12)$$

求其对偶函数

10.2.4 等式约束条件下的范数极小化

对偶函数：

$$g(\nu) = \inf_x (\|x\| - \nu^T Ax + b^T \nu) = \begin{cases} b^T \nu & \|A^T \nu\|_* \leq 1 \\ -\infty & \text{其他情况} \end{cases}$$

其中 $\|v\|_* = \sup_{\|u\| \leq 1} u^T v$ 是 $\|\cdot\|$ 的对偶范数。

最优值下界：如果 $\|A^T \nu\|_* \leq 1$, $p^* \geq b^T \nu$

10.2.4 等式约束条件下的范数极小化

证明.

对全部的 x , 当 $\|y\|_* \leq 1$, $\inf_x (\|x\| - y^T x \geq 0)$, 否则为 $-\infty$

- 如果 $\|y\|_* \leq 1$, 那么对所有 x , $\|x\| - y^T x \geq 0$, 当 $x = 0$ 时取等
- 如果 $\|y\|_* > 1$, 令 $x = tu$ 其中 $\|u\| \leq 1, u^T y = \|y\|_* > 1$:

$$\|x\| - y^T x = t(\|u\| - \|y\|_*) \rightarrow -\infty \quad \text{当 } t \rightarrow \infty$$

